



Lending Club 의 포트폴리오 수익률 최대화 방안

1 조

김병현 박준희 이지환 정한직 조하영 황현범

1. 서론

1.1. Lending Club 개요

Lending Club 은 2006 년에 설립된 미국의 대표적인 P2P(Peer-to-Peer) 대출 플랫폼이었습니다. 이 플랫폼은 전통적인 금융기관을 거치지 않고 대출자와 투자자를 직접 연결하여 개인 및 중소기업이 자금을 조달할 수 있도록 지원합니다. 이 과정에서 Lending Club 은 대출자에게는 낮은 금리로 자금을 제공하고, 투자자에게는 높은 수익률을 제시함으로써 금융 시장에 혁신적인 영향을 미치고 있습니다.

1.2. Lending Club 의 사업 구조

이전 Lending Club 의 비즈니스 모델은 다음과 같은 주요 요소들로 구성되어 있습니다.

(1) 대출자 (Borrowers)

대출 신청 및 신용 평가: 대출자는 Lending Club 의 온라인 플랫폼을 통해 대출을 신청하며, 이 과정에서 Lending Club 은 자체 개발한 신용 평가 모델을 사용하여 대출자의 신용도를 평가합니다. 이를 통해 적합한 금리가 설정되고, 대출 승인 여부가 결정됩니다.

(2) 투자자 (Investors)

투자 및 수익: 투자자는 Lending Club 플랫폼을 통해 다양한 대출 상품에 투자할 수 있습니다. 투자자는 이자 수익을 통해 이익을 얻으며, 다양한 대출에 소액으로 분산 투자함으로써 리스크를 관리할 수 있습니다.

(3) Lending Club 의 수익 모델


수수료 기반에서 여신 기반으로: Lending Club 은 대출자에게 대출 발행 수수료를, 투자자에게 관리 수수료를 부과함으로써 수익을 창출하였습니다. 플랫폼에서 이루어지는 거래가 많아질수록 수익이 증가하는 구조로 설계되어 있었습니다. 하지만 2020 년에 래디어스 은행을 인수하고 p2p 대출 플랫폼 사업에서 인터넷 전문 은행으로 비즈니스 모델을 변환하면서 대출위주의 수익구조를 가지게 되었습니다.

따라서 현재 Lending Club 의 현재 비즈니스 모델은 은행의 상황과 유사하다고 판단됩니다. 가용할 수 있는 자본을 토대로 최대한 수익을 높이기 위해서는 대출자의 비중과 기타 다른 투자처를 비교하여 대출 승인 여부를 결정해야 합니다. 은행 대출의 위험도의 경우 신용도, 담보 등을 토대로 산정하기에, 타 투자처인 부동산, 주식 등의 위험도보다는 낮다고 판단됩니다. 따라서 대출과 비슷하게 매월 이자를 받을 수 있으며, 시세차익을 통해서 추가적인 수익을 노릴 수 있는 채권을 비교 대상으로 선정하여 대출과 채권을 토대로 포트폴리오를 최적화하고자 하였습니다.

2. Lending Club 데이터

2.1. 데이터 개요

- (1) 기간 : 2007.06 ~ 2020.09
- (2) Rows : 1,755,295 / Columns : 141
- (3) 결측치 : 1669387 개, 결측치에 대한 분석은 [그림 1]과 같이 진행했습니다.



[그림 1] 결측치 분석을 위한 상관관계 분석의 일부

2.2. 데이터 생성 시점 정리 [부록 1]

일반적인 대출 절차 상, 고객은 대출을 받기 전에 본인의 정보를 은행에 넘기고 그 데이터를 통해서 은행으로부터 예상 되는 금리와 예상되는 월 납입금액을 안내 받게 됩니다. 따라서 `int_rate` 와 `installment` 는 대출 전에 생성 될 수 있는 정보라고 판단하여 데이터 생성 시점이 대출 이전이라고 판단했습니다.

2.3. EDA (탐색적 데이터 분석) [부록 2]


Boxplot, grophistogram, kdeplot 을 변수들에 대해 그려봄으로써 데이터를 시각적으로 이해하고자 하였습니다. box plot 을 통해 이상치가 있어 보이는 feature 들이 있음을 확인했습니다. 또한 histogram 과 kdeplot 을 통해 정규분포를 따르지 않는 변수들이 많은 것을 확인했습니다. 따라서 이상치에 민감한 SVM 과 linear model 류는 제외하며 Tree 계열의 RandomForest 와 XGboost, Lightgbm 과 DNN model 을 추후 사용 모델로 선택했습니다.

2.4. 결측치 처리

결측치의 경우 최대한 정보를 보존할 수 있는 방법이 있다면 그대로 하되, 없으면 해당 행을 삭제하는 방안으로 진행하였습니다. 아래의 7 개 열은 결측치를 median 혹은 mean 값으로 대체하였습니다.

- Median 으로 대체:
mths_since_recent_bc, mths_since_recent_inq, mo_sin_old_il_acct,
mths_since_recent_bc_dlq, mths_since_recent_revol_delinq, num_bc_ssats
- Mean 으로 대체: bc_util


sec- 으로 시작하는 이름을 가진 열의 경우 공동 보증인이 있을 경우 값이 있는 것을 확인하였습니다. 따라서 공동 보증인이 없는 경우는 0 으로 대체했습니다. 이외의 열의 경우 [그림 2]와 같이 (Sub)grade 와 연관이 있는 것이 확실해 보인다면, sub_grade 를 기준으로 bootstrapping 하여 채웠습니다.



[그림 2] grade 별 연관성 파악


2.5. 이상치 처리

[그림 3]과 같이 빈도에 의해 graph 에 점이 찍혀있지 않아 이상치로 분류되는 경우, 만약 값이 너무 크더라도 중간에 값이 연속적으로 이어져 있고 물리, 제도적으로 불가능한 경우가 아니라면 이상치가 아니라고 판단하였습니다. 또한 위의 결측치를 처리할 때, 행을 삭제할 경우 이상치가 없어지는 경우가 있었으며, 이 경우 이상치에 대한 처리를 하지 않았습니다.



[그림 3] 이상치 처리 사례 1

[그림 4]와 같이 만약 명백하게 이상치이나 위의 결측치의 처리와 같이 대체할 수 있는 값이 없다고 판단될 경우, 해당 데이터(row)만 삭제하였습니다. (dti, annual_inc, tot_hi_cred_lim)



[그림 4] 이상치 처리 사례 2

모기지 계좌 수(mort_acc) 변수의 경우, 한번에 하나의 기관에서 대출을 받는 한국과 달리 미국은 재융자(refinancing)를 통해서 여러 모기지 계좌를 동시에 갖는 것이 가능합니다. 이 때문에 많은 이용자들의 여러개의 계좌를 가졌기에 이상치가 없다고 판단하였습니다. 이 외 기타 이상치 처리를 거친 변수와 처리 방법은 다음과 같습니다.

- annual_inc: 극단값으로 나타난 row 2 개 삭제
- num_bc_tl : 61 개 까지는 1 차 사용, 63-89 까지는 2 차 사용
- revol_util : 최대값 row 1 개 삭제
- tot_hi_cred_lim: 9999999 값이 나오는 row 2 개 삭제
- last_fico_range_high: 0 인 값들은 subgrade 에 따라 bootstrapping
- last_fico_range_low: last_fico_range_high 와 높은 상관관계를 가지므로 열 삭제

3. 목표 설정

3.1. 대출 방식

대출의 방식은 매 주기 상환하는 금액을 어떻게 선정하는지에 따라 크게 두 가지 방식으로 나뉩니다. 이때, 랜딩 클럽은 원리금 균등 상환으로 매달 상환해야 하는 금액을 산출합니다.

(1) 원리금 균등 상환

Lending Club 에서 사용하는 방식으로, 원리금 균등 상환 방식은 매 주기마다 동일한 금액의 원리금(원금과 이자의 합)을 상환하는 방식입니다. 이 방식은 매 주기마다 상환하는 총 금액은 동일하기에, 대출자가 일정한 금액을 계속해서 상환할 수 있도록 합니다.

매달 상환금액을 산정하는 공식은 다음과 같습니다.

$$installment = \frac{P \times r \times (1 + r)^n}{(1 + r)^n - 1}$$

$installment$ = 매달 상환해야 하는 금액 (원리금)

P = 대출 원금

r = 월 이자율 (연 이자율을 12로 나눈 값)

n = 총 상환 회차 (상환 기간을 월 단위로 계산)

3.2. 채권

(1) 정의

채권은 정부, 기업 등이 자금을 조달하기 위해 발행하는 고정 수익 증권입니다. 채권은 발행 주체가 원금과 일정한 이자를 지급하겠다는 약속으로 발행됩니다. 국가에서 발행하는 채권이 가장 안정적이라고 간주되며, 랜딩클럽의 국적에 따라 미국 국채를 사용했습니다. 채권은 만기 별로 단기, 중기, 장기 채로 구분되며, 본 프로젝트에서는 랜딩클럽의 대출 주기와 같은 3년 만기와 5년 만기 채권의 수익률을 사용합니다.

(2) 수집 방법

Fred API 이용: Fred API 를 통해 미국 재무부 채권의 수익률 데이터를 수집했습니다. 이는 미국 연방준비은행의 경제 데이터(FRED)에서 제공하는 데이터입니다. 아래의 만기 수익률 역시 제공되어 이를 비교에 사용하였습니다.

(3) 수익률

채권의 수익률(Yield to Maturity, YTM)은 채권의 현재 시장 가격과 매입 후 만기 시까지의 총 수익을 고려하여 계산됩니다. 이를 계산하는 공식은 일반적으로 아래와 같은 수식으로 표현됩니다.

$$YTM \approx \frac{C + \frac{F - P}{n}}{\frac{F + P}{n}}$$

C = 매년 지급되는 쿠폰 이자 (Coupon Payment)

F = 채권의 액면가 (Face Value)

P = 채권의 현재 시장 가격 (Price)

n = 채권의 만기까지 남은 기간 (Years to Maturity)

3.3. ETF

(1) 정의

ETF(Exchange-Traded Fund)는 특정 지수를 추종하거나 특정 자산군에 투자하는 상장지수펀드입니다. ETF는 주식처럼 거래되며, 채권, 주식, 상품 등 다양한 자산에 투자할 수 있는 장점을 가지고 있습니다. 본 프로젝트에서는 포트폴리오에서 채권의 비중이 높은 ETF를 비교 수익률로 선정했습니다.

(2) 수집 방법

ETF의 가격과 배당금 데이터는 Yahoo Finance의 API를 통해 수집했습니다.

(3) 최종 선정 ETF

ETF 선정 기준은 다음과 같습니다.


첫째, 2007년 이전 5년간의 수익률, 배당금 데이터가 있을 것. 본 연구에서는 2007년 1월 기준으로 이전 3년, 5년의 수익률을 기준으로 수익률 비교를 진행했기에, 2007년 이전 5년 데이터가 있는 ETF를 선정했습니다.

둘째, 90%이상 미국 국채에 투자하는 ETF 일 것. 투자의 목표는 시장의 무위험보다 높은 수익을 내는 것 입니다. 따라서, 무위험에 가까운 수익을 보이기 위해서는 포트폴리오에서 국채의 비중이 높아야 합니다.

셋째, 미국 단기채 ETF 운용자산 규모가 상위 5위 내에 있을 것. 운용규모가 클 수록 거래량이 많아 유동성이 높기에 유동성 위험에서 벗어날 수 있습니다. 따라서 운용자산 규모가 큰 ETF를 선정했습니다.

위 조건을 모두 만족하는 ETF 는 스테이트스트리트글로벌어드바이저(SSGA)에서 운용하는 iShares 1-3 Year Treasury Bond ETF(이하 SHY)입니다. SHY 는 2002 년 7 월부터 운용을 시작했으며, 포트폴리오의 약 98% 국채에 투자하고 있습니다. (전체 중 98.90%를 Bonds 에, Bonds 의 99%를 국채에 투자하고 있습니다.)

Asset Allocation



[그림 5] ETF 현황

3.4. 최종 기대 수익률 계산

원리금 균등상환 방식의 경우 고객이 지불한 돈이 월 내야 할 경우보다 적을 경우 낸 돈으로 이자를 먼저 상환하게 됩니다. 예를 들어서 월 납부할 금액이 150 만원이 이중 100 만원이 대출 원금, 50 만원이 이자라고 할 때, 채무자가 100 만원을 납부 했다면 이자 50 만원이 먼저 납부 되고 원금 50 만원이 상환 되며, 남은 50 만원은 연체가 됩니다. 따라서 대출 기간 후의 대출 상환액이 0% 이상이라면 이자는 전부 냈다고 생각을 할 수 있습니다. 또한 대출의 원금을 모두 갚지 못하더라도, 이자율에 따라서 이미 상환된 원금과 납부된 이자의 합을 통해 계산한 수익이 채권의 수익률을 넘어설 수 있습니다. 이에 따라서 개인 대출 수익의 근사치는 다음과 같이 계산할 수 있습니다.

$$\text{개인 대출 근사치} = \frac{(\text{원금 상환 비율} \times \text{원금}) + (\text{이자율} \times \text{원금})}{\text{원금}}$$


이때 회사의 기대 수익률은 다음과 같이 정의 됩니다.

$$E(\max(\text{개인 수익률}, \text{채권 수익률}, \text{ETF 수익률}))$$

3.5. 수익률의 측정

- (1) 수익률($\text{total_pymnt}/\text{funded_amnt}$): 3%
- (2) 이벤트 등이 없을 때(Non marketing)의 수익률: 8.8%

여기서 'Non marketing'이란, 마케팅 비용이나 프로모션 등의 추가적인 비용 지출 없이, 순수하게 대출 계약 조건에 따라 산출된 이론적인 수익률을 의미합니다.



[그림 6] Gross Rate

위 그래프는 installment 공식과 실제 상환 비율을 이용해 구한 상환 기간을 곱해서 구한 Gross rate 에서 총상환금액/원금을 기준으로 계산한 Gross rate 를 뺀 것입니다.

$$\text{Non Marketing rate} = \frac{\text{installment} \times \text{상환 기간}}{\text{funded_amnt}}$$

$$\text{Difference of gross rate} = \text{non marketing rate} - \frac{\text{total_pymnt}}{\text{funded_amnt}}$$

histogram 이 양수쪽으로 치우친 것을 보아 $\text{total_pymnt}/\text{funded_amnt}$ 가 낮은 것을 확인할 수 있습니다. 이는 자동 이체시 이자율을 감면해주는 프로모션 등을 통해서 납부해야 할 이자액을 일부 보전해서 실제 수익률이 낮아진 것으로 보입니다. 총상환금/원금을 기준으로 하면 약 3%정도의 수익률을 보이지만, 감면 없이 모두 받았을 경우의 수익률은 8.8%입니다. 따라서 기준이 되는 수익률(Non marketing 수익률)을 8.8%로 하도록 하겠습니다.

위의 식에서 채권수익률의 경우 계산식을 통해서 정해지는 일종의 상수라고 볼 수 있습니다. 또한 ETF의 경우 3년(5년) 대출이라면 `issue_d` 기준 3년(5년)치의 기대수익률 통해서 구할 수 있습니다. 하지만 원금 상환 비율의 경우 대출 이전의 정보를 토대로 상환 비율을 예측할 수 밖에 없습니다. 또한 수익률이 marketing 등의 비용이 포함되어 있기 때문에, 이러한 비용을 더한 순수 매출을 계산하기 위해 `target` 을 gross rate 가 아닌 원금 상환비율로 하며, 이를 통해서 상환 기간을 구해 현금흐름을 측정하겠습니다. 마지막으로 위의 공식을 적용할 경우 상환 비율이 1은 아니지만 이자율이 높아 빌려주는 것이 좋은 고객이 있을 수 있습니다. IRR의 경우 같은 기간의 현금흐름을 요구하기 때문에 전부 상환하지 않은 사람의 수익과 채권, ETF 수익과의 비교는 편차를 발생시킬 가능성이 높습니다. 따라서 단순한 Gross rate 를 이용해서 수익률을 비교하고 측정하겠습니다.

$$\text{Target} = \frac{\text{total_rec_prncp}}{\text{funded_amnt}}$$

3.6. Target의 정합성

종속변수(Target)를 앞서 정의한 바와 같이 설정한 이유는 특정 대출자의 사전 정보가 주어졌을 때, 해당 대출자로부터 원금을 어느 정도로 회수할 수 있는지 예측하기 위함입니다. 이는 수익성을 보다 정확하게 예측하기 위함이며, 모델 훈련 과정에서 각 대출자들이 기간 내에 상환을 완료하였는지 혹은 상환에 실패했는지가 아니라, 어느 정도의 비율만큼 원금 회수에 성공하였는지를 파악하는 데 중점을 둡니다.

종속변수(Target)가 의미하는 바는 ‘원금 상환 비율’로, 0과 1 사이의 값을 가져야 합니다. 종속변수의 유효성을 확인하기 위해 전체 데이터셋에서 계산된 Target 값을 조사해본 결과, 부동소수점으로 인한 오차를 감안하여 Target 값이 1.0001 이상인 경우는 존재하지 않음을 확인했습니다.

보다 자세히 살펴보기 위해 ‘`loan_status`’에 따라 데이터를 ① [‘Fully Paid’, ‘Does not meet the credit policy. Status:Fully Paid’] ② ‘Current’ ③ 그 외의 경우로 나누어 Target 값을 조사해보았습니다.

①의 경우, 원금 상환 비율인 Target 값이 1로 계산되어야 하는데, 총 899,745 건의 자료 중 Target 값이 오차를 감안하여 0.999보다 작은 경우가 1 건(이 경우 Target 값은 0.966이었음) 존재했으며, 이는 극히 일부이므로 예외적인 경우로 판단했습니다.

②와 ③의 경우 Target 값이 1보다 작게 계산되어야 합니다. 우선 ②의 경우, 총 618,688 건의 자료 중 Target 값이 오차를 감안하여 0.99보다 큰 경우가 6,652 건 존재하였습니다. 하지만, 해당 데이터들의 ‘`last_pymnt_d`’ 열의 값을 조사해본 결과, 6,652 건 모두 마지막 상환일이 2020년으로 파악되었습니다. 이는 렌딩클럽의 대출서비스 종료시점을 고려했을 때,

2020 년 대출 상환이 완료된 대출들(조기 상환 포함)에 대해 ‘loan_status’ 열의 값을 업데이트하지 않았던 것이라 판단하였습니다.

마지막으로 ③ 의 경우, 총 236,861 건의 자료 중 Target 값이 오차를 감안하여 0.99 보다 큰 경우가 282 건 존재하였습니다. 이 중에는 ‘last_pymnt_amnt’(가장 최근 상환 금액)이 ‘installment’(월 지불금액) 보다 크거나, ‘recoveries’(회수금)의 값이 양수인 경우를 비롯하여 Charged Off 이후 원금을 모두 상환한 것으로 추정되는 경우도 있는가 하면, 이유를 알 수 없는 케이스도 존재했습니다. 그러나 전체에 비하면 극히 일부에 불과하며, 이유를 추정할 수 있는 경우는 원금을 결국 모두 회수했다고 볼 수 있으므로 원금 상환 비율을 Target 으로 정하여도 문제가 없다고 판단하였습니다.

4. 변수 선택


4.1. Linear Regression (Stepwise)

Stepwise 방식을 통해 사용한 변수를 나타내면 아래 [표 1]과 같습니다.

variable	linear regression (step wise)	variable	linear regression (step wise)
annual_inc	0	initial_list_status	0
inq_last_6mths	-	collections_12_mths_ex_med	0
sub_grade	0	mths_since_last_major_derog	0
int_rate	0	policy_code	-
installment	0	annual_inc_joint	0
tot_cur_bal	0	dti_joint	0
avg_cur_bal	0	verification_status_joint	0
mo_sin_old_rev_tl_op	0	acc_now_delinq	0
mo_sin_rcnt_rev_tl_op	0	open_acc_6m	0
mo_sin_rcnt_tl	0	open_il_12m	0
mort_acc	0	open_il_24m	0
num_il_tl	0	mths_since_rcnt_il	0
num_tl_120dpd_2m	-	total_bal_il	0
num_tl_op_past_12m	0	il_util	0
revol_bal	-	open_rv_12m	0
total_bc_limit	0	total_rev_hi_lim	0
dti	0	total_cu_tl	0
tot_hi_cred_lim	0	inq_last_12m	0
loan_amnt	0	bc_open_to_buy	0
term	0	bc_util	0
emp_length	0	delinq_amnt	0
home_ownership	0	mo_sin_old_il_acct	0
purpose	0	mths_since_recent_bc	0
delinq_2yrs	0	mths_since_recent_bc_dlq	0
revol_util	0	mths_since_recent_inq	0
application_type	0	mths_since_recent_revol_delinq	0
open_act_il	0	num_accts_ever_120_pd	0
open_rv_24m	-	num_actv_bc_tl	0
max_bal_bc	0	num_actv_rev_tl	0
all_util	0	num_bc_sats	0
acc_open_past_24mths	0	num_bc_tl	0
num_op_rev_tl	0	num_rev_tl_bal_gt_0	0
num_rev_accts	0	num_sats	0
num_tl_90g_dpd_24m	0	num_tl_30dpd	-
pct_tl_nvr_dlq	0	percent_bc_gt_75	0
last_fico_range_high	0	total_bal_ex_mort	0
verification_status	0	total_il_high_credit_limit	0
open_acc	0	revol_bal_joint	0
pub_rec_bankruptcies	0	sec_app_fico_range_high	0
pub_rec	0	sec_app_inq_last_6mths	0
tax_liens	0	sec_app_mort_acc	0
chargeoff_within_12_mths	0	sec_app_open_acc	0
pymnt_plan	-	sec_app_revol_util	0
fico_range_high	0	sec_app_open_act_il	0
mths_since_last_delinq	0	sec_app_num_rev_accts	0
total_acc	0	sec_app_chargeoff_within_12_mths	-
initial_list_status	0	sec_app_collections_12_mths_ex_med	0

[표 1] Stepwise 방식 변수 선택 결과

Onehot Encoding 을 통해 상관관계 히트맵을 그린 결과를 [그림 7]에서 확인할 수 있습니다.



[그림 7] Onehot Encoding 후 상관관계 히트맵

4.2. 파생 변수 설정

- $\text{bar_ex_mort_year} = \text{total_bal_ex_mort} / \text{annual_inc}$: 모기지를 제외하고 남은 기존 대출금액/연소득 : 기존 대출액을 앞으로 몇년을 더 갚아야 할지 나타냅니다.
- $\text{loan_year} = \text{loan_amnt} / \text{annual_inc}$: 신청인이 신청한 대출 금액을 갚는데 몇년이 걸리는지 나타냅니다.
- $\text{bar_il_year} = \text{total_bal_il} / \text{annual_inc}$: 총 할부 잔액을 갚는데 몇년이 걸리는지 나타냅니다.

5. 모델 설정 (Tree, DNN)

5.1. 데이터 특성 분석 및 모델 선택 근거

EDA 결과, 우리의 데이터셋은 약 170 만 개의 행과 141 개의 열로 구성되어 있으며, 많은 변수들이 정규분포를 따르지 않는 것으로 나타났습니다. 또한 일부 변수에서 이상치가 관찰되었습니다. 이러한 데이터 특성을 고려하여, 이상치에 민감한 linear regression과 적합 속도가 느리고 이상치에 민감한 SVM을 제외하기로 결정했습니다. 대신, 이상치에 상대적으로 강건한 Tree 계열 모델(LightGBM, RandomForest, XGBoost)과 DNN을 선택했습니다.

(1) 사용 모델

- LightGBM
- Random Forest
- XGBoost
- DNN

모델	Linear Regression	SVM	LightGBM	RandomForest	XGBoost	DNN
이상치에 민감	O	O	X	X	X	X
적합속도	O	O	X	X	X	X
선택	X	X	O	O	O	O

5.2. 목표 변수(Target) 클리핑

목표 변수는 원금 상환 비율로 설정했으며, 이는 0 부터 1 사이의 값을 가집니다. 따라서, 0 미만의 예측치는 0 으로, 1 초과 예측치는 1 로 조정하였습니다.

5.3. 평가 지표 및 데이터 전처리

(1) Metric (MAE, MSE) 설정 이유

원금 상환의 비율을 정확하게 예측하는 것이 수익률에 도움이 될 것이라고 판단하여 MAE 를 주 지표로 MSE 와 R^2 을 보조 지표로 설정하였습니다.

(2) 데이터 전처리

Standard Scaling 으로 설정하였습니다.

6. 최종 선택 모델과 파라미터, 결과

6.1. 모델의 성능 평가 및 채택

1 차적으로 모델을 테스트한 결과, LightGBM 은 과적합이 발생하여 모델 후보에서 제했습니다. 최종적으로 모든 데이터 셋, Stepwise linear regression 으로 선택한 86 개 데이터셋, 이에 3 개의 파생변수를 추가한 89 개 열을 가진 데이터 셋에 대해 성능 평가를 진행했습니다.

결과적으로 파생변수를 추가했을 때의 XGBoost 와 DNN 의 성능이 준수하여 Tree 모델과 신경망 모델을 각각 한 개씩 선정했습니다.


	모든 데이터	LinearRegression (stepwise)	파생변수 추가
XGBoost	0.0929	0.0958	0.0914
RandomForest	0.1327	0.1309	0.1319
DNN	0.0907	0.0891	0.0885

7. 최종 수익률 계산

3.목표 설정에서 논의한 수익률 계산 방식을 토대로 산정한 최종 수익률입니다.

7.1. DNN

DNN 을 통해서 예측한 원금상환 비율을 이용해서 아래의 공식을 이용해서 구한 수익률과 분포는 다음과 같습니다.




DNN 수익률	11.5%
Non marketing 수익률	8.8%

예측된 수익률은 11.5%이며, 기준 분포와 유사합니다. 하지만 0.4~1, 1.05 부근의 예측이 과대평가 되고 있습니다.

7.2. XGBoost

XGBoost 를 통해 예측한 원금상환 비율을 이용해서 아래의 공식을 이용해서 구한 수익률과 분포는 다음과 같습니다.



예측된 수익률은 12.8%이며, 기준 분포와 유사합니다. 하지만 0.5~1.1 부근의 예측이 과대평가되고 있습니다.

7.3. 성능 평가와 해석

$\text{Max}(\text{Non marketing rate}, \text{ETF 기대수익률}, \text{채권수익률})$ 을 통한 포트폴리오 최적화 수익률은 다음과 같습니다.


	Non marketing (Original)	DNN	XGboost
수익률	19.97%	19.31%	19.5%

전체적으로 실제 데이터의 수익률보다 조금 낮은 경향을 보이는 것을 알 수 있습니다. 위의 예측과 다소 다른 부분이 있음에도 비슷한 포트폴리오 수익률을 보이는 이유 주로 예측이 틀린 구간이 원금 상환비율이 낮은 구간이기 때문인 것으로 보입니다. 상환비율이 낮은 개인은 채권 및 ETF와의 수익률 비교에서 자동적으로 없어집니다. 따라서, error가 낮아진 것으로 보입니다.


8. 극단적인 케이스에서의 SHAP Value

8.1. SHAP value 결과

SHAP value 분석 결과는 아래 그림과 같습니다.



[그림 8] DNN SHAP values




[그림 9] XGBoost SHAP values

(1) 극단적인 케이스

a. 신용점수가 높음에도 미상환(부도)


i) XGBoost

last_fico_range_high: 804 , 예측값 : 0.42050



ii) DNN


last_fico_range_high : 703 , 예측값 : 0.17704



b. 신용점수가 낮음에도 전부상환


i) XGBoost

last_fico_range_high: 644, 예측값 : 1



ii) DNN

last_fico_range_high : 499, 예측값 : 0.991518



위의 네가지 데이터를 비교하여 봤을 때, 신용점수가 높음에도 원금 상환 비율이 낮은 이유는 공동보증인의 여부로 보입니다. 공동보증인이 있는 경우는 신용점수가 높음에도 상환한 비율이 적고, 없는 경우에는 신용점수가 낮음에도 상환하였습니다.

9. Test set 결과

9.1. 결과 요약

- MAE: DNN 0.088 | XGboost 0.091
- total_pymnt/funded_amnt : 3.4 %
- Non marketing rate: 8.7%

Train 데이터와 거의 비슷한 분포를 보이는 것을 알 수 있습니다.

9.2. Portfolio

- Original 19.96%
- DNN rate: 20.21%
- XGboost rate: 19.3%

분석 결과, Train 데이터와 비슷한 수익률을 보이는 것을 알 수 있습니다. 모델과 전략 모두 Robust 합니다.

10. 시사점 및 향후과제

10.1. 시사점

본 연구를 통해 Tree 계열 모델(XGBoost)과 신경망 모델(DNN)이 대출 상환 예측에 효과적임을 확인했습니다. 또한, SHAP 분석을 통해 공동보증인의 여부가 신용점수와 상환 비율 간의 관계에 중요한 영향을 미친다는 것을 발견했습니다. 이는 대출 심사 과정에서 공동보증인의 존재가 중요한 고려 사항이 될 수 있음을 나타내며, 향후 대출 정책 수립에 있어 유용한 인사이트를 제공합니다. 이러한 발견들은 대출 리스크 관리와 포트폴리오 최적화 전략 수립에 있어 중요한 기초 자료로 활용될 수 있을 것입니다.

10.2. 향후 과제

(1) 기준 금리 도입

현재 연구에서는 미국 국채의 기대수익을 과거 3 년 또는 5 년의 운용 수익률을 기반으로 산정했습니다. 그러나 미국 국채의 기대수익은 미국 기준금리의 영향을 크게 받습니다. 따라서 향후 연구에서는 과거 운용 수익률 대신 미래의 기준금리를 예측, 비교를 통해 기대수익을 선정하는 방법을 고려해야 합니다. 이러한 접근은 현재와 미래의 시장 상황을 더 정확히 반영하여, 보다 높은 수익률을 도출할 수 있을 것입니다.

(2) 포트폴리오 최적화

대출과 채권 투자의 기대값과 분산을 토대로 평균-분산 최적화 방법을 활용한 포트폴리오 최적화를 시도해 볼 수 있습니다. 이를 통해 더 효율적인 자산 배분이 가능할 것입니다.

Appendices

[부록 1] 데이터 생성 시점에 따른 변수 분류

데이터 생성 시점 구분 대출 이전

```
`acc_now_delinq, acc_open_past_24mths, all_util, annual_inc, annual_inc_joint,
application_type, avg_cur_bal, bc_open_to_buy, bc_util, chargeoff_within_12_mths,
collections_12_mths_ex_med, delinq_2yrs, delinq_amnt, dti, dti_joint, emp_length,
fico_range_high, il_util, inq_last_12m, inq_last_6mths, initial_list_status,
int_rate, last_fico_range_high, loan_amnt, max_bal_bc, mo_sin_old_il_acct,
mo_sin_old_rev_tl_op, mo_sin_rcnt_rev_tl_op, mo_sin_rcnt_tl, mort_acc,
mths_since_last_delinq, mths_since_last_major_derog, mths_since_rcnt_il,
mths_since_recent_bc, mths_since_recent_bc_dlq, mths_since_recent_inq,
mths_since_recent_revol_delinq, num_accts_ever_120_pd, num_actv_bc_tl,
num_actv_rev_tl, num_bc_sats, num_bc_tl, num_il_tl, num_op_rev_tl, num_rev_accts,
num_rev_tl_bal_gt_0, num_sats, num_tl_120dpd_2m, num_tl_30dpd, num_tl_90g_dpd_24m,
num_tl_op_past_12m, open_acc, open_acc_6m, open_act_il, open_il_12m, open_il_24m,
open_rv_12m, open_rv_24m, pct_tl_nvr_dlq, policy_code, pub_rec,
pub_rec_bankruptcies, purpose, pymnt_plan, revol_bal, revol_bal_joint, revol_util,
sec_app_chargeoff_within_12_mths, sec_app_collections_12_mths_ex_med,
sec_app_fico_range_high, sec_app_inq_last_6mths, sec_app_mort_acc,
sec_app_num_rev_accts, sec_app_open_acc, sec_app_open_act_il, sec_app_revol_util,
sub_grade, tax_liens, term, tot_cur_bal, tot_hi_cred_lim, total_acc,
total_bal_ex_mort, total_bal_il, total_bc_limit, total_cu_tl,
total_il_high_credit_limit, total_rev_hi_lim, verification_status,
verification_status_joint`
```


데이터 생성 시점 구분 대출 이후

```
`collection_recovery_fee, funded_amnt, funded_amnt_inv, last_credit_pull_d,
last_pymnt_amnt, last_pymnt_d, out_prncp, out_prncp_inv, recoveries, tot_coll_amt,
total_pymnt, total_pymnt_inv, total_rec_int, total_rec_late_fee, total_rec_prncp`
```


[부록 2] EDA 결과 (Boxplot, Group histogram, Kdeplot)

(1) Boxplot


outdata_boxplot_2




Boxplot_visual




Boxplot_visual




Boxplot_visual




Boxplot_visual







Boxplot_visual



(2) Group Histogram









(3) Kdeplot


outdata_kde_2




kdeplot




kdeplot




kdeplot




kdeplot



kdeplot



[부록 3] 신용등급별 연간 이자율 추이



[부록 4] 연도별 평균 상환율 추이

